

Comparação de indutores para modelos de predição de classificação de imagens

Lucas Mrowskovsy Paim*

2019

Resumo

Este trabalho tem por objetivo comparar os indutores apresentados durante a disciplina de Machine Learning do programa de especialização em Inteligência Artificial Aplicada da Pontifícia Universidade Católica do Paraná, para predição de classificação de imagens, utilizando principalmente a biblioteca scikit-learn e a linguagem Python, assim como a demonstração de técnicas de combinação de indicadores e seleção dinâmica.

Tem por objetivo também a comparação dos resultados utilizando técnicas de extração de características manuais, handcrafted, e CNN deep-learning.

Para a extração de características de imagens foram utilizados as bibliotecas: opencv-python, skimage e keras

//Falta a conclusão

Palavras-chave: Naive Bayes. Árvores de decisão. Redes Neurais. k-Vizinhos Mais Próximos. Máquina de Vetores de Suporte.

Abstract

This paper aims to compare the inductors presented during the Machine Learning discipline of the Pontifical Catholic University of Paraná specialization program in Applied Artificial Intelligence, to predict image classification using mainly the scikit-learn library and the Python language as well as the demonstration of techniques of combination of indicators and dynamic inductor selection.

It also aims to compare the results using handcrafted and CNN deep-learning feature extraction techniques.

*Programa de Pós Graduação em Inteligência Artificial, Curitiba - PR, 80215-901; Especializando em Inteligência Artificial Aplicada na PUCPR; Tecnólogo em Sistemas para Internet pela Universidade Positivo; E-mail: lucasmpaim1@gmail.com

For the extraction of image characteristics we used the libraries: opencv-python, skimage and keras.

Keywords: Naive Bayes. Decision Tree. Neural Network. k-Nearest Neighbors. Support Vector Machine.

1 Introdução

A utilização de classificadores de imagens é utilizada nas mais diversas áreas do conhecimento, que vão desde o auxílio de diagnóstico de câncer de pele [Soares \(2008\)](#), sistemas de segmentação e classificação de imagens via satélite [Erhal et al. \(1991\)](#), OCR's (Optical Character Recognition) para reconhecimento de textos e dígitos [Ribas et al. \(2012\)](#) etc.

Os mesmos indutores também podem ser utilizados para outras finalidades que não sejam classificação de imagem, como: detecção de emoções em processamento de textos [Dosciatti, Ferreira e Paraiso \(2013\)](#), regressão linear etc.

Segundo [Coppin \(2004\)](#), fornecer a capacidade de visão a sistemas computacionais, assim como a robôs, agentes é algo, sem dúvida, extremamente desejável.

As técnicas de extração de características de imagens handcrafted que foram utilizadas são:

- LBP: Local Binary Pattern: Segundo, [Rosebrock \(2015\)](#), esta é uma técnica de extração de texturas de uma imagem, em que cada pixel é comparado com seus vizinhos a partir de uma máscara e com isso é gerado uma sequência binária que toma o lugar daquele pixel.
- HOG: Histogram of Oriented Gradients: Segundo [Mallick \(2016\)](#) é uma técnica de extrai a distribuição (Histogramas) de direções de gradientes.
- Histograma de Cores RGB.

Visto o exposto o estudo desse trabalho se torna importante para a área de classificação de imagens, Podendo ser aplicado em diversas áreas, tendo por objetivo criar modelos de predição para classificação de imagens comparando vários indutores e os combinando para gerar maiores assertividades.

2 Método

A base utilizada para este trabalho, conta com apenas mil imagens, separadas em dez classes com cem imagens cada, sendo assim, é uma base completamente balanceada.

Todos os indutores, foram treinados utilizando a mesma base de imagens, em um primeiro momento ela é separada em 70% em treinamento e 30% em testes, técnica esta chamada de holdout (percentage-split), após esta separação ainda foi separado mais 30% da base de treinamento e criada uma base de validação, para evitar assim o chamado overfitting, que segundo [Sarle \(2016\)](#), é um dos maiores problemas da aprendizagem de máquina, isto indica que o indutor está perdendo sua capacidade de generalização, isto é,

segundo [Lima, Pinheiro e Santos \(2014\)](#) a capacidade do indutor responder adequadamente a dados que não fazem parte do conjunto de treinamento.

Para a comparação dos indutores será avaliado, com base em holdout e também em validação cruzada que segundo, [Britto \(2019b\)](#), consiste em dividir a base de dados em N grupos, em que um desses grupos é selecionado para teste e isto é repetido N vezes, garantindo assim que todas as instâncias serão utilizadas como teste ao menos uma vez.

Devido ao não suporte dos métodos de overfitting para alguns indicadores, este trabalho utiliza, quando disponível, o método:

```
.partial_fit(X, y, [classes])
```

Este método segundo [learn \(2019\)](#), é ideal para treinamento incremental, sendo assim, é possível estender a lógica do early stopping para alguns indicadores que não suportam tal método nativamente, como o Naive Bayes.

Como o método incremental, tende a adicionar ruído na base de dados, foi utilizado o método de IIR (Infinite Impulse Response), que segundo [Grout \(2008\)](#) é um filtro recursivo em que a saída do filtro é calculada usando as entradas atuais e anteriores e as saídas anteriores, fazendo assim com que o ruído seja minimizado, este filtro foi aplicado no tratamento de erro tanto da base de validação quanto da base de teste.

Sua fórmula consiste em:

$$y_t = \sum_{i=0}^M b_j x(t-i) - \sum_{j=1}^L \alpha_j y(t-j) \quad (1)$$

O resultado da aplicação desta técnica pode ser consultada na [Figura 1](#), onde é possível observar que o gráfico foi suavizado, de forma que, quando ambas as bases forem confrontadas será possível detectar mais facilmente onde está ocorrendo o overfitting.

Sendo assim podemos definir a taxa de aprendizado como sendo:

$$r = y_{t-1} - y_t \quad (2)$$

Onde y_{t-1} se refere ao erro na base de validação na iteração anterior e y_t se refere a iteração atual de treinamento, desta forma quando obtemos um valor para $r < 10^{-3}$ que é a taxa mínima de aprendizagem e isso ocorre por N vezes seguidas, significa que não há um ganho no treinamento e este pode ser interrompido.

2.1 Naive Bayes

Segundo, [Britto \(2019a\)](#), o teorema de Bayes consiste em uma abordagem probabilística para aprendizagem, calculando assim a probabilidade de uma característica X de um vetor de prever determinada classe.

A técnica de Naive Bayes, assume que todas as características no vetor são independentes, por isso, é chamado de Naive (do inglês Ingênuo), pois determinadas características podem estar relacionadas entre si, o que faz com que essa técnica tenha um resultado inferior a técnica de Redes Bayesianas que consideram que os atributos podem ou não ser relacionados, isto é, a característica X pode ou não estar diretamente relacionada a característica Y .

2.1.1 Resultados do Treinamento

A matriz de confusão para o esta técnica usando houldout e a base de características usando deeplearning pode ser consultada em [Figura 3](#), assim como sua taxa de aprendizagem [Figura 2](#)

Acurácia Naive Bayes Validação : 0.8928571428571429
Acurácia Naive Bayes Teste : 0.9266666666666666

Para o método usando as características extraídas de forma hand crafting, a curva de erro na aprendizagem pode ser consultado na [Figura 4](#), assim como sua matriz de confusão na [Figura 5](#).

Acurácia Naive Bayes Validação : 0.7785714285714286
Acurácia Naive Bayes Teste : 0.8533333333333334

2.2 Árvores de decisão

A técnica da árvore de decisão utiliza a teoria do ganho de informação (entropia) , para decidir seus novos vértices até que consiga realizar a classificação das instâncias.

A entropia pode ser definida pela fórmula:

$$S = -p_+ \log_2 p_+ - p_- \log_2 p_- \quad (3)$$

Onde p_+ é a proporção de elementos positivos em S e p_- a de elementos negativos.

As árvores geradas para a este trabalho podem ser consultadas em: [Figura 6](#), [Figura 8](#)

2.2.1 Resultados do Treinamento

DEEP

Acurácia Decision Tree Teste : 0.8466666666666667

HAND-CRAFT

Acurácia Decision Tree Teste : 0.67

2.3 Redes Neurais

2.3.1 Resultados do Treinamento

DEEP

Acurácia Neural Network - adam Validação : 0.9357142857142857
Acurácia Neural Network - adam Teste : 0.92

HAND-CRAFT

Acurácia Neural Network - adam Validação: 0.10714285714285714
Acurácia Neural Network - adam Teste : 0.1

2.4 KNN

A técnica de k-nearest neighbors, k-vizinhos mais próximos, consiste em agrupar instâncias similares, e quando novas instâncias são inseridas para a classificação, elas são classificadas pelos k -vizinhos mais próximos.

Uma grande desvantagem desta abordagem que dispensa treinamento é que ela é mais lenta, uma vez que realiza todos os cálculos necessários a cada nova classificação

2.4.1 Resultados

DEEP

Acurácia KNN Teste : 0.96

HAND-CRAFT

Acurácia KNN Teste : 0.3966666666666667

2.5 SVM

A técnica de SVM consiste em "encontrar" novas dimensões para classificar os atributos

2.5.1 Resultado do Treinamento

DEEP

Acurácia SVM Teste : 0.9833333333333333

HAND-CRAFT

Acurácia SVM Teste : 0.7533333333333333

3 Resultados

Os indutores tiveram resultados mais consistentes utilizando a base com características extraídas via deep-learning, que por mais que tenha menos características que a base que utilizou hand-crafting, estas características representam melhor o problema.

Utilizando a técnica t-SNE, que segundo [Maaten \(2019\)](#), é uma técnica de redução de dimensionalidade estocástica, ou seja, utilizando esta técnica é possível reduzir um vetor de tamanho N para um de tamanho X , foi realizada a redução das bases de características e apresentadas graficamente, para assim analisar o quão bem distribuídos estão as classes, estes gráficos podem ser conferidos na [Figura 10](#) e [Figura 11](#)

É possível notar que os pontos na [Figura 11](#) estão extremamente misturados, o que dificulta a classificação, com isso seria necessário um trabalho de limpeza de características ou a extração de novas características que representem melhor o problema.

4 Considerações finais

Referências

- BRITTO, A. *Aprendizagem Bayesiana*. 2019. Ppgia. Disponível em: <<http://www.ppgia.pucpr.br/~alceu/am/4%20-%20Naive%20Bayes%20and%20Bayesian%20Networks/NaiveBayes.pdf>>. Acesso em: 25 set 2019. Citado na página 3.
- BRITTO, A. *Conceitos Básicos*. 2019. Ppgia. Disponível em: <<http://www.ppgia.pucpr.br/~alceu/am/1%20-%20Introduction%20to%20ML/Conceitos%20B%e1sicos.pdf>>. Acesso em: 22 set 2019. Citado na página 3.
- COPPIN, B. *Inteligência Artificial*. 1. ed. Rio de Janeiro: LTC - Livros Técnicos e Científicos Editora S.A., 2004. Acesso em: 22 set 2019. Citado na página 2.
- DOSCIATTI, M. M.; FERREIRA, L. P. C.; PARAISO, E. C. *Identificando Emoções em Textos em Português do Brasil usando Máquina de Vetores de Suporte em Solução Multiclasse*. 2013. PPGIA. Disponível em: <<http://www.ppgia.pucpr.br/~paraiso/mineracaodeemocoas/recursos/emocoasENIAC2013.pdf>>. Acesso em: 21 set 2019. Citado na página 2.
- ERHAL, G. J. et al. *Um Sistema de Segmentação e Classificação de Imagens De Satélite*. 1991. INPE. Disponível em: <<http://sibgrapi.sid.inpe.br/col/sid.inpe.br/sibgrapi/2012/09.28.17.13/doc/Um%20sistema%20de%20segmentacao%20e%20classificacao.pdf>>. Acesso em: 21 set 2019. Citado na página 2.
- GROUT, I. *Learn more about Infinite Impulse Response*. 2008. Sciencedirect. Disponível em: <<https://www.sciencedirect.com/topics/computer-science/infinite-impulse-response>>. Acesso em: 24 set 2019. Citado na página 3.
- LEARN scikit. *Incremental learning*. 2019. Scikit-learn. Disponível em: <https://scikit-learn.org/0.18/modules/scaling_strategies.html#incremental-learning>. Acesso em: 24 set 2019. Citado na página 3.
- LIMA, I.; PINHEIRO, C. A. M.; SANTOS, F. A. O. *Inteligência Artificial*. 1. ed. Rio de Janeiro: CAMPUS, 2014. Acesso em: 22 set 2019. Citado na página 3.
- MAATEN, L. van der. *Aprendizagem Bayesiana*. 2019. Lvdmaaten. Disponível em: <<https://lvdmaaten.github.io/tsne/>>. Acesso em: 25 set 2019. Citado na página 5.
- MALLICK, S. *Histogram of Oriented Gradients*. 2016. Learnopencv. Disponível em: <<https://www.learnopencv.com/histogram-of-oriented-gradients/>>. Acesso em: 22 set 2019. Citado na página 2.
- RIBAS, F. C. et al. *Handwritten digit segmentation: a comparative study*. 2012. UFPR. Disponível em: <<http://www.inf.ufpr.br/lesoliveira/download/IJDAR2012.pdf>>. Acesso em: 22 set 2019. Citado na página 2.
- ROSEBROCK, A. *Local Binary Patterns with Python & OpenCV*. 2015. Pyimagesearch. Disponível em: <<https://www.pyimagesearch.com/2015/12/07/>>

[local-binary-patterns-with-python-opencv/>](#). Acesso em: 22 set 2019. Citado na página 2.

SARLE, W. S. *Stopped Training and Other Remedies for Overfitting*. 2016. Overfitting. Disponível em: <https://s3.amazonaws.com/academia.edu.documents/31153602/1329.pdf>. Acesso em: 22 set 2019. Citado na página 2.

SOARES, H. B. *Análise e Classificação de Imagens de lesões da pele por atributos de cor, forma e textura utilizando máquina de vetor de suporte*. 2008. UFRN. Disponível em: https://repositorio.ufrn.br/jspui/bitstream/123456789/15118/1/HelianaBS_TESE.pdf. Acesso em: 21 set 2019. Citado na página 2.

APÊNDICE A – Nullam elementum urna vel imperdiet sodales elit ipsum pharetra ligula ac pretium ante justo a nulla curabitur tristique arcu eu metus


Nunc velit. Nullam elit sapien, eleifend eu, commodo nec, semper sit amet, elit. Nulla lectus risus, condimentum ut, laoreet eget, viverra nec, odio. Proin lobortis. Curabitur dictum arcu vel wisi. Cras id nulla venenatis tortor congue ultrices. Pellentesque eget pede. Sed eleifend sagittis elit. Nam sed tellus sit amet lectus ullamcorper tristique. Mauris enim sem, tristique eu, accumsan at, scelerisque vulputate, neque. Quisque lacus. Donec et ipsum sit amet elit nonummy aliquet. Sed viverra nisl at sem. Nam diam. Mauris ut dolor. Curabitur ornare tortor cursus velit.

Morbi tincidunt posuere arcu. Cras venenatis est vitae dolor. Vivamus scelerisque semper mi. Donec ipsum arcu, consequat scelerisque, viverra id, dictum at, metus. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut pede sem, tempus ut, porttitor bibendum, molestie eu, elit. Suspendisse potenti. Sed id lectus sit amet purus faucibus vehicula. Praesent sed sem non dui pharetra interdum. Nam viverra ultrices magna.

Agradecimentos


Texto sucinto aprovado pelo periódico em que será publicado. Último elemento pós-textual.

Figura 1 – Comparação do Erro com e sem IIR, usando Holdout




Fonte: O Autor

Figura 2 – Gráfico de Margem de erro usando Holdout




Fonte: O Autor

Figura 3 – Matrix de confusão Naive Bayes, usando Holdout




Fonte: O Autor

Figura 4 – Gráfico de treinamento Naive Bayes, usando Holdout



Fonte: O Autor

Figura 5 – Matrix de confusão Naive Bayes, usando Holdout




Fonte: O Autor

Figura 6 – Decision Tree, usando Holdout e Deep Learning




Fonte: O Autor

Figura 7 – Matrix de confusão Decision Tree, usando Holdout e Deep Learning




Fonte: O Autor

Figura 8 – Árvore de Designação, usando Holdout e Hand Craft




Fonte: O Autor

Figura 9 – Matrix de confusão Decision Tree, usando Holdout e Hand Craft




Fonte: O Autor

Figura 10 – TSNE Base Deep Learning



Fonte: O Autor

Figura 11 – TSNE Base Hand Crafting



Fonte: O Autor